



*Master en Ingeniería Informática*

Datos Masivos y Encadenados 25/26

Grupo 1

*Práctica Datos Masivos*

## «Visualización de transportes públicos y privados en Nueva York»

---

Eduardo Alarcón Navarro — 100472175

Laura Belizón Merchán — 100452273

*Profesor*

Israel González Carrasco

## Resumen Ejecutivo

.

**Palabras clave:**

## Tabla de contenidos

|                                                                   |          |
|-------------------------------------------------------------------|----------|
| <b>1. Análisis y diseño del problema de integración propuesto</b> | <b>3</b> |
| 1.1. Fuentes de datos utilizadas                                  | 3        |
| 1.2. Software para la recopilación de datos                       | 4        |
| 1.3. Arquitectura del sistema                                     | 5        |
| 1.3.1. Arquitectura materializada                                 | 5        |
| 1.3.2. Arquitectura virtual                                       | 5        |
| <b>2. Prueba de Concepto</b>                                      | <b>6</b> |
| <b>3. Conclusiones</b>                                            | <b>7</b> |
| <b>Bibliografía</b>                                               | <b>8</b> |
| <b>A. Integración de Datos en tiempo real de redes sociales</b>   | <b>9</b> |

# 1. Análisis y diseño del problema de integración propuesto

La movilidad en las ciudades es un aspecto crucial para el bienestar de sus habitantes y el desarrollo económico. En este proyecto, nos centramos en la visualización de datos relacionados con los transportes públicos y privados en Nueva York y su posible relación con otros factores urbanos, como puede ser la violencia, para identificar patrones y tendencias que puedan ayudar a mejorar la planificación urbana y la seguridad.

Para poder llevar a cabo este análisis, hemos recopilado datos de diversas fuentes, incluyendo conjuntos de datos abiertos proporcionados por el gobierno de Nueva York y otras organizaciones. Estos datos incluyen información sobre el uso de bicicletas públicas (Citi Bike), datos de taxis amarillos y verdes, así como estadísticas de uso de transporte público, autobuses y metro, y datos sobre incidentes de violencia en la ciudad.

Con estos datos, creemos que se puede obtener información sobre la violencia en distintas áreas de la ciudad y su posible relación con el uso del transporte público y privado. Por ejemplo, podríamos analizar si hay una mayor incidencia de crímenes en áreas con alta densidad de estaciones de bicicletas públicas o si ciertas rutas de taxis están asociadas con mayores tasas de violencia. También nos gustaría poder incluir datos sobre la meteorología, para comprobar si el uso de transportes varía en función de las condiciones climáticas.

Como valor añadido al proyecto, nos gustaría explorar la posibilidad de incorporar datos en tiempo real, como actualizaciones de tráfico o alertas de seguridad, para proporcionar una visión más dinámica y actualizada de la movilidad y la seguridad en Nueva York. Con esto, se podría ver cómo los eventos en tiempo real afectan al uso del transporte y a la incidencia de crímenes. También se podría predecir patrones futuros basándonos en datos históricos y tendencias actuales o incluir datos sobre redes sociales para poder intentar prever situaciones de riesgo o de colapso de las infraestructuras de transporte.

## 1.1. Fuentes de datos utilizadas

Para llevar a cabo este proyecto, hemos utilizado diversas fuentes de datos abiertos y públicos relacionados con el transporte y la violencia en Nueva York. A continuación, se detallan las principales fuentes de datos utilizadas:

**Tabla 1:** Source of data for the project, including the last update

| Clave              | Fuente                                 | Enlace                                                                                                                                                                                                                      | Año  |
|--------------------|----------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------|
| taxi_trips         | TLC Trip Record Data                   | <a href="https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page">https://www.nyc.gov/site/tlc/about/tlc-trip-record-data.page</a>                                                                                     | 2025 |
| mta_daily          | MTA Daily Ridership Data: 2020 - 2025  | <a href="https://data.ny.gov/Transportation/MTA-Daily-Ridership-Data-2020-2025/vxuj-8kew/about_data">https://data.ny.gov/Transportation/MTA-Daily-Ridership-Data-2020-2025/vxuj-8kew/about_data</a>                         | 2025 |
| mta_bus_hourly     | MTA Bus Hourly Ridership: 2020-2024    | <a href="https://data.ny.gov/Transportation/MTA-Bus-Hourly-Ridership-2020-2024/kv7t-n8in/about_data">https://data.ny.gov/Transportation/MTA-Bus-Hourly-Ridership-2020-2024/kv7t-n8in/about_data</a>                         | 2024 |
| nyc_crime          | NYC Citywide Crime Statistics          | <a href="https://www.nyc.gov/site/nypd/stats/crime-statistics/citywide-crime-stats.page">https://www.nyc.gov/site/nypd/stats/crime-statistics/citywide-crime-stats.page</a>                                                 | 2025 |
| nyc_shooting_crime | NYPD Shooting Incident Data (Historic) | <a href="https://data.cityofnewyork.us/Public-Safety/NYPD-Shooting-Incident-Data-Historic-/833y-fsy8/about_data">https://data.cityofnewyork.us/Public-Safety/NYPD-Shooting-Incident-Data-Historic-/833y-fsy8/about_data</a> | 2025 |
| nyc_city_bike      | Citi Bike Trip Histories               | <a href="https://citibikenyc.com/system-data">https://citibikenyc.com/system-data</a>                                                                                                                                       | 2025 |

La periodicidad de los datos depende de cada fuente, pero para realizar este estudio, hemos comprobado que todas las distintas fuentes tienen datos desde 2020 hasta Octubre de 2025, lo que nos permite realizar un análisis coherente y completo. La granularidad de los datos varía según la fuente, pero en general, los datos están disponibles a nivel de día o de evento, el cual tiene una marca temporal precisa.

**1.2. Software para la recopilación de datos**

Para la recopilación y procesamiento de los datos que no son en tiempo real, hemos utilizado Rust como lenguaje de programación principal para obtener los datos de las distintas fuentes, ya que ofrece un buen rendimiento y una gestión eficiente de la memoria. Además, hemos utilizado Python para tareas de análisis de datos y visualización, ya que cuenta con una amplia gama de bibliotecas especializadas en este ámbito, como Pandas, Matplotlib y Seaborn. En concreto, hemos utilizado la librería `TODO`: para la visualización de datos geoespaciales, que nos ha permitido crear mapas interactivos y

detallados de Nueva York, mostrando la distribución de los transportes y los incidentes de violencia en la ciudad.

Para recopilar información en tiempo real, hemos utilizado las APIs disponibles, como la API del tiempo de OpenWeatherMap para obtener datos meteorológicos. En un futuro, nos gustaría explorar la posibilidad de utilizar APIs de tráfico en tiempo real y alertas de seguridad para enriquecer aún más nuestro análisis.

### 1.3. Arquitectura del sistema

Para nuestro proyecto, hemos optado por una arquitectura híbrida, que combina de una arquitectura materializada y una arquitectura virtual. Esta elección se basa en la necesidad de manejar grandes volúmenes de datos históricos, así como en la capacidad de integrar datos en tiempo real para un análisis más dinámico.

#### 1.3.1. Arquitectura materializada

La parte materializada de nuestra arquitectura se centra en el almacenamiento y procesamiento de los datos históricos recopilados de las diversas fuentes. Concretamente, los datos de taxis, bicicletas públicas, estadísticas de crimen y el uso del transporte público se almacenan en una base de datos relacional optimizada para consultas analíticas. Esta base de datos permite realizar consultas complejas y análisis detallados de los patrones de movilidad y violencia en Nueva York a lo largo del tiempo.

#### 1.3.2. Arquitectura virtual

La parte virtual de nuestra arquitectura se enfoca en la integración de datos en tiempo real. Utilizamos APIs para obtener datos actualizados sobre el tiempo en la ciudad, y en un futuro, planeamos incorporar datos de tráfico y alertas de seguridad, así como datos sobre redes sociales.<sup>1</sup>

Esta combinación de arquitecturas nos permite aprovechar al máximo los datos históricos para el análisis profundo, mientras que la integración de datos en tiempo real nos proporciona una visión actualizada y dinámica de la movilidad y la seguridad en Nueva York. Esta arquitectura híbrida es flexible y escalable, permitiéndonos adaptarnos a futuras necesidades y la incorporación de nuevas fuentes de datos conforme el proyecto evoluciona. No nos es necesario almacenar los datos en tiempo real de forma persistente, ya que su valor radica en su inmediatez y actualidad.

---

<sup>1</sup>«Ver el Apéndice A. para más detalles sobre la integración de datos en tiempo real.»

## 2. Prueba de Concepto

Para la realización de la prueba de concepto, hemos utilizado un segmento de los datos, para comprobar la viabilidad de las técnicas de visualización y análisis propuestas. Hemos seleccionado datos de taxis amarillos, así como datos de incidentes de violencia en la ciudad, para un período de 1 meses, concretamente diciembre de 2024. Este período nos permite observar patrones y tendencias en el uso del transporte y su posible relación con la violencia en la ciudad en un mes muy activo, ya que se celebran las navidades, atrayendo a muchos turistas y transportes adicionales.

### **3. Conclusiones**

## **Bibliografía**

## A. Integración de Datos en tiempo real de redes sociales

La integración de datos con redes sociales no se plantea en esta fase del proyecto debido a limitaciones de tiempo y recursos, pero es una línea de trabajo futura que consideramos muy interesante para enriquecer el análisis. Sin invertir dinero, la API de Twitter tiene limitaciones en cuanto a la cantidad de datos que se pueden obtener, en concreto 100 mensajes al mes, lo que dificulta la obtención de una muestra representativa para un análisis significativo.

Esto se puede observar en las capturas de la página de X-API (Twitter) que se muestran a continuación, donde se ve que en un período de 30 días, solo se pueden obtener 100 tweets, lo que limita la capacidad de análisis y visualización de datos

### Projects

Default project-1997273181128933376




Figura 1: Limitaciones de la API de Twitter para la obtención de datos gratuitos

También se muestra el precio de las distintas opciones de suscripción a la API de Twitter, que ofrecen un mayor acceso a los datos, pero que implican un coste económico que no hemos podido asumir en esta fase del proyecto.

| X API access levels and versions                                                                                                                                                                                   |                   |                    |                    |             |
|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|-------------------|--------------------|--------------------|-------------|
| While the X API v2 is the primary X API, the platform currently supports previous versions (v1.1, Gnip 2.0) as well. We recommend that all users start with v2 as this is where all future innovation will happen. |                   |                    |                    |             |
| The X API v2 includes a few access levels:                                                                                                                                                                         |                   |                    |                    |             |
|                                                                                                                                                                                                                    | Free              | Basic              | Pro                | Enterprise  |
| Getting access                                                                                                                                                                                                     | Get Started       | Get Started        | Get Started        | Get Started |
| Price                                                                                                                                                                                                              | Free              | \$200/month        | \$5000/month       | -           |
| Access to X API v2                                                                                                                                                                                                 | ✓                 | ✓                  | ✓                  | ✓           |
| Access to standard v1.1                                                                                                                                                                                            | ✓ (Limited)       | ✓ (Limited)        | ✓ (Limited)        | ✓           |
| Project limits                                                                                                                                                                                                     | 1 Project         | 1 Project          | 1 Project          | -           |
| App limits                                                                                                                                                                                                         | 1 App per Project | 2 Apps per Project | 3 Apps per Project | -           |
| Post caps (per month)                                                                                                                                                                                              | 100               | 15,000             | 1,000,000          | -           |
| Enterprise stream APIs                                                                                                                                                                                             | ✗                 | ✗                  | ✗                  | ✓           |
| Filtered stream API                                                                                                                                                                                                | ✗                 | ✗                  | ✓                  | ✓           |
| Access to full-archive search                                                                                                                                                                                      | ✗                 | ✗                  | ✓                  | ✓           |

Figura 2: Opciones de suscripción a la API de Twitter y sus precios